

ПРАКТИЧЕСКАЯ 2: РАБОТА С ДАННЫМИ — ЗАГРУЗКА, ОЧИСТКА И ПОДГОТОВКА

Ожидаемое время выполнения: 3 часа (1 час — импорт данных, 1 час — очистка, 1 час — сравнение и анализ).

Цель практики

Изучить методы загрузки и очистки данных в Python, R и Glarus BI, а также освоить базовые инструменты для подготовки данных к анализу.

Задачи практики

1. Загрузить данные из различных источников (CSV, Excel, базы данных) в Python, R и Glarus BI.
2. Выполнить очистку данных:
 - Обнаружить и обработать пропуски (удаление, замена на среднее/медиану).
 - Обнаружить и удалить дубликаты.
 - Преобразовать типы данных (например, текст в даты).
3. Использовать инструменты Glarus BI для очистки данных:
 - Фильтрация данных по условию.
 - Трансформация столбцов (например, создание нового столбца на основе вычислений).
4. Сравнить подходы к очистке данных в Python, R и Glarus BI.

Формат отчета

1. Введение:
 - 1.1. Цель и задачи работы.
 - 1.2. Описание используемых источников данных и типов данных.
2. Результаты работы:
 - 2.1. Скриншоты интерфейса Glarus BI:
 - 2.1.1. Импорт данных из различных источников.
 - 2.1.2. Пример фильтрации и трансформации данных.
 - 2.2. Скрипты Python и R для загрузки данных и выполнения очистки.
 - 2.3. Примеры обработки пропусков и дубликатов в Python, R и Glarus BI.
 - 2.4. Сравнительная таблица: подходы к очистке данных в каждом инструменте.
3. Заключение:
 - 3.1. Преимущества и недостатки каждого инструмента при очистке данных.
 - 3.2. Рекомендации по выбору инструмента в зависимости от типа задачи.

Дополнительные материалы к практической работе 2

Исходные данные: Разнообразные наборы данных (CSV, Excel), возможно, данные из открытых баз данных (например, SQLite).

ПОШАГОВАЯ ИНСТРУКЦИЯ К ПРАКТИЧЕСКОЙ РАБОТЕ 2

Шаг 1. Загрузка данных из различных источников

1.1. Загрузка данных в Glarus BI

1. Перейдите в раздел загрузки данных.
2. Выберите источник данных:
 - CSV или Excel: укажите путь к файлу и загрузите его.
 - База данных (например, SQLite): укажите параметры подключения и выберите таблицу для импорта.
3. Убедитесь, что данные корректно отображаются в таблице после загрузки.

1.2. Загрузка данных в Python (Google Colab)

1. Загрузите CSV-файл:

Листинг 2.1 Загрузка файла формата csv

```
from google.colab import files
uploaded = files.upload() # Загрузка локального файла
import pandas as pd
df = pd.read_csv(list(uploaded.keys())[0])
print(df.head())
```

2. Загрузите данные из Excel:

Листинг 2.2 Загрузка данных из файла Excel

```
df_excel = pd.read_excel('путь_к_файлу.xlsx')
print(df_excel.head())
```

3. Загрузите данные из базы данных SQLite:

Листинг 2.3 Загрузка данных из базы данных

```
import sqlite3
conn = sqlite3.connect('путь_к_базе.db')
query = "SELECT * FROM название_таблицы"
df_sql = pd.read_sql(query, conn)
print(df_sql.head())
```

1.3. Загрузка данных в R (RStudio)

1. Загрузите CSV-файл:

Листинг 2.4 Загрузка файла формата csv

```
library(readr)
df <- read_csv("путь_к_файлу.csv")
head(df)
```

2. Загрузите данные из Excel:

Листинг 2.5 Загрузка данных из файла Excel

```
library(readxl)
df_excel <- read_excel("путь_к_файлу.xlsx")
head(df_excel)
```

3. Загрузите данные из базы данных SQLite:

Листинг 2.6 Загрузка данных из базы данных

```
library(DBI)
conn <- dbConnect(RSQLite::SQLite(), dbname = "путь_к_базе.db")
df_sql <- dbGetQuery(conn, "SELECT * FROM название_таблицы")
head(df_sql)
```

Шаг 2. Очистка данных

2.1. Glarus BI

1. Перейдите в раздел очистки данных.
2. Обнаружьте пропуски данных: используйте встроенные фильтры или инструменты анализа пропусков.
3. Удалите или замените пропуски (например, средним значением).
4. Найдите дубликаты и удалите их с помощью инструментов фильтрации или группировки.
5. Преобразуйте типы данных, если необходимо (например, преобразование текста в даты).

2.2. Python (Google Colab)

1. Обнаружьте пропуски:

Листинг 2.7 Обнаружение пропусков

```
print(df.isnull().sum()) # Количество пропусков в каждом столбце
```

2. Замените пропуски средним значением:

Листинг 2.8 Замена пропусков средним значением

```
df['Столбец'] = df['Столбец'].fillna(df['Столбец'].mean())
```

3. Удалите дубликаты:

Листинг 2.9 Удаление дубликатов

```
df = df.drop_duplicates()  
print("Дубликаты удалены.")
```

4. Преобразуйте типы данных:

Листинг 2.10 Преобразование типа данных

```
df['Дата'] = pd.to_datetime(df['Дата'])  
print(df.dtypes)
```

2.3. R (RStudio)

1. Обнаружьте пропуски:

Листинг 2.11 Обнаружение пропусков

```
colSums(is.na(df))
```

2. Замените пропуски средним значением:

Листинг 2.12 Замена пропусков средним значением

```
df$Столбец[is.na(df$Столбец)] <- mean(df$Столбец, na.rm = TRUE)
```

3. Удалите дубликаты:

Листинг 2.13 Удаление дубликата

```
df <- df[!duplicated(df), ]  
print("Дубликаты удалены.")
```

4. Преобразуйте типы данных:

Листинг 2.14 Преобразование типа данных

```
df$Дата <- as.Date(df$Дата, format = "%Y-%m-%d")  
str(df)
```

Шаг 3. Использование инструментов Glarus BI для очистки данных

1. Загрузите данные в интерфейсе Glarus BI.
2. Выполните фильтрацию по заданному условию (например, строки с пропусками или строки с дубликатами).
3. Преобразуйте или создайте новый столбец с вычисляемыми

значениями (например, преобразование формата дат или расчет дополнительных метрик).

Шаг 4. Сравнение подходов к очистке данных

1. Сравните эффективность очистки данных в Python, R и Glarus BI:
 - Время выполнения операций.
 - Количество ручных шагов.
 - Возможности визуализации промежуточных данных.
2. Постройте таблицу для сравнения:
 - Обнаружение пропусков.
 - Обработка дубликатов.
 - Преобразование типов данных.

Формат отчета

1. Введение:
 - 1.1. Цель и задачи работы.
 - 1.2. Описание используемых источников данных и типов данных.
2. Результаты работы:
 - 2.1. Скриншоты интерфейса Glarus BI:
 - Импорт данных из различных источников.
 - Пример выполнения фильтрации и трансформации данных.
 - 2.2. Скрипты Python и R для загрузки данных и выполнения очистки.
 - 2.3. Примеры обработки пропусков и дубликатов в Python, R и Glarus BI.
 - 2.4. Сравнительная таблица: подходы к очистке данных в каждом инструменте.
3. Заключение:

- 3.1. Преимущества и недостатки каждого инструмента при очистке данных.
- 3.2. Рекомендации по выбору инструмента в зависимости от типа задачи.