



МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение
высшего образования

«МИРЭА – Российский технологический университет»

РТУ МИРЭА

**Институт информационных технологий (ИИТ)
Кафедра прикладной математики (ПМ)**

**ОТЧЕТ ПО ПРАКТИЧЕСКОЙ РАБОТЕ №2
«РАБОТА С ДАННЫМИ - ЗАГРУЗКА, ОЧИСТКА И
ПОДГОТОВКА»**

по дисциплине «Языки программирования для статистической обработки
данных»

Студент группы

ИНБО-20-23. Боргачев Т.М.

(подпись)

Преподаватель

Трушин СМ

(подпись)

Москва 2025 г.

ВВЕДЕНИЕ

Цель практики: изучить методы загрузки и очистки данных в Python, R и Glarus BI, а также освоить базовые инструменты для подготовки данных к анализу.

Задачи практики:

1. Загрузить данные из различных источников (CSV, Excel, базы данных) в Python, R и Glarus BI.
2. Выполнить очистку данных:
 - Обнаружить и обработать пропуски (удаление, замена на среднее/медиану).
 - Обнаружить и удалить дубликаты.
 - Преобразовать типы данных (например, текст в даты).
3. Использовать инструменты Glarus BI для очистки данных:
 - Фильтрация данных по условию.
 - Трансформация столбцов (например, создание нового столбца на основе вычислений).
4. Сравнить подходы к очистке данных в Python, R и Glarus BI.

РЕЗУЛЬТАТЫ РАБОТЫ

Загрузка данных из разных источников

Загрузка данных в Glarus BI

Для начала загрузим данные в Glarus. Результат загрузки представлен на рис. 1.

Car Model	Condition	Mileage	Price (usd)	Monthly Payment	Dealer Name	Glarus Load Dtm
2023 BMW M2 Base	Used	2,496 mi.	\$63,000	Est. \$1,184/mo	Murgado Ford of Chicago	21 февраля, 2025, 16:12
2020 Dodge Charger SXT	Used	98,302 mi.	\$14,995	Est. \$282/mo	Blue Sky Auto Sales - Brighton Park	21 февраля, 2025, 16:12
2016 Scion IM Base	Used	72,040 mi.	\$12,690	Est. \$239/mo	Mcgrath Evanston Subaru	21 февраля, 2025, 16:12
2022 Volvo XC60 Recharge Plug-In Hybrid TB Inscription	Used	31,580 mi.	\$38,998	Est. \$733/mo	CarMax Birmingham	21 февраля, 2025, 16:12
2012 Mitsubishi Lancer SE	Used	54,197 mi.	\$9,995	Est. \$188/mo	Moto Zone Inc.	21 февраля, 2025, 16:12
2023 Chevrolet Bolt EUV FWD LT	Used	19,045 mi.	\$18,995	Est. \$357/mo	Luxury Motors Credit	21 февраля, 2025, 16:12
1984 BMW 733i 733i	Used	139,186 mi.	\$17,985	Est. \$338/mo	Chicago Cars US	21 февраля, 2025, 16:12
2017 Toyota Highlander XLE	Used	84,581 mi.	\$23,998	Est. \$451/mo	CarMax Charleston	21 февраля, 2025, 16:12
2021 Lexus ES 250 250	Used	25,336 mi.	\$29,708	Est. \$558/mo	The Autobarn Volkswagen of Countryside	21 февраля, 2025, 16:12
2025 Chevrolet Trailblazer LT	New		\$27,970	Est. \$526/mo	Jennings Chevy / VW	21 февраля, 2025, 16:12
2017 Lexus GS 350 F Sport	Used	44,156 mi.	\$30,888	Est. \$581/mo	Chicago Auto Place	21 февраля, 2025, 16:12
2020 Lincoln Continental Reserve	Used	48,625 mi.	\$31,395	Est. \$590/mo	Napleton Autowerks River Oaks	21 февраля, 2025, 16:12
2021 Lexus ES 250 250	Used	13,860 mi.	\$33,995	Est. \$639/mo	Lombard Toyota	21 февраля, 2025, 16:12
2014 Cadillac CTS-V Base	Used	12,664 mi.	\$52,995	Est. \$996/mo	D&M Motorsports	21 февраля, 2025, 16:12
2020 Lexus RC 350 F Sport	Used	30,200 mi.	\$36,700	Est. \$690/mo	Volvo Cars Little	21 февраля, 2025, 16:12
2011 Audi TTS 2.0T Premium Plus	Used	54,116 mi.	\$29,995	Est. \$619/mo	Auto Showcase of Carol Stream	21 февраля, 2025, 16:12

Рисунок 1 – Данные, загруженные в Glarus BI

Загрузка данных в Python

Скрипт для загрузки данных на языке Python представлен в Листинге 1.

Листинг 1 – Загрузка данных в Python

```
import pandas as pd
df = pd.read_csv("combined_data.csv")
df.head()
```

Загрузка данных в R

Скрипт для загрузки данных на языке R представлен в Листинге 2.

Листинг 2 – Загрузка данных в R

```
library(readr)
df <- read_csv("combined_data.csv")
head(df)
```

Очистка данных

Очистка в Glarus BI

В Glarus BI очистка данных возможна путем фильтрации пустых значений. Результат обработки пропусков представлен на рис. 2.

ClickHouse_Test / combined_data / 152b44a817ad5026a0e43752555facc4

6

Фильтр

Суммировать

Сохранить

Car Model is not empty

Condition is not empty

Mileage is not empty

Price (usd) is not empty

Monthly Payment is not empty

Dealer Name is not empty

Car Model	Condition	Mileage	Price (usd)	Monthly Payment	Dealer Name	Glarus Load Dttm
2018 Mercedes-Benz AMG GLE 43 Coupe 4MATIC	Used	43,527 mi.	\$39,495	Est. \$742/mo	Adam Auto Group	21 февраля, 2025, 16:12
2017 BMW M6 Base	Used	47,920 mi.	\$42,480	Est. \$798/mo	Lucky Motors Megastore of Villa Park	21 февраля, 2025, 16:12
2002 Lexus SC 430 Base	Used	104,295 mi.	\$12,990	Est. \$244/mo	Auto Gallery Chicago	21 февраля, 2025, 16:12
2015 Ford C-Max Hybrid SE	Used	76,014 mi.	\$10,980	Est. \$206/mo	Star Motor Sales	21 февраля, 2025, 16:12
2019 MINI Clubman John Cooper Works ALL4	Used	73,154 mi.	\$19,800	Est. \$372/mo	Packey Webb Ford	21 февраля, 2025, 16:12
2021 Nissan Rogue Sport S	Nissan Cer...	61,555 mi.	\$16,493	Est. \$310/mo	Zeigler Nissan of Orland Park	21 февраля, 2025, 16:12
1974 Triumph TR6 Base	Used	48,375 mi.	\$29,000	Est. \$545/mo	Ultimate Motor Cars	21 февраля, 2025, 16:12
2017 BMW M6 Base	Used	30,398 mi.	\$41,995	Est. \$789/mo	Greater Chicago Motors	21 февраля, 2025, 16:12
2022 Jeep Compass (RED) Edition 4x4	Used	21,101 mi.	\$25,497	Est. \$479/mo	Napleton Lincoln of Schaumburg	21 февраля, 2025, 16:12
2007 Honda S2000 Base	Used	43,854 mi.	\$32,800	Est. \$617/mo	Diamond Motorworks	21 февраля, 2025, 16:12
2007 BMW M6 Base	Used	66,276 mi.	\$17,900	Est. \$336/mo	Exotic Motors	21 февраля, 2025, 16:12
2015 BMW 535 Gran Turismo xDrive	Used	90,257 mi.	\$17,500	Est. \$329/mo	Car City Inc	21 февраля, 2025, 16:12
2004 Lexus RX 330 Base	Used	209,500 mi.	\$5,990	Est. \$113/mo	Car City Inc	21 февраля, 2025, 16:12
2018 FIAT 500 Lounge	Used	15,160 mi.	\$15,955	Est. \$300/mo	McGrath City Hyundai	21 февраля, 2025, 16:12

Рисунок 2 – Обработка пропусков в Glarus BI

Для удаления дубликатов достаточно сгруппировать значения по каждому из столбцов и поставить фильтр на количество равное единице. Результат удаления дубликатов представлен на рис. 3.

Car Model is not empty

Condition is not empty

Mileage is not empty

Price (usd) is not empty

Monthly Payment is not empty

Dealer Name is not empty

Количество is equal to 1

Condition	Car Model	Mileage	Price (usd)	Monthly Payment	Dealer Name	Glarus Load Dttm: Day	Количество
Acura Certified	2021 Acura TLX Base	20,691 mi.	\$26,744	Est. \$503/mo	Muller's Woodfield Acura	21 февраля, 2025	1
Acura Certified	2021 Acura TLX Base	38,906 mi.	\$30,389	Est. \$571/mo	Muller's Woodfield Acura	21 февраля, 2025	1
Acura Certified	2021 Acura TLX FWD	52,613 mi.	\$22,998	Est. \$432/mo	Arlington Acura in Palatine	21 февраля, 2025	1
Acura Certified	2022 Acura ILX Technology & A-Spec Packages	35,965 mi.	\$26,490	Est. \$498/mo	Joe Rizza Acura	21 февраля, 2025	1
Acura Certified	2022 Acura MDX Technology	39,435 mi.	\$38,999	Est. \$733/mo	McGrath Acura of Morton Grove	21 февраля, 2025	1
Acura Certified	2022 Acura TLX FWD	14,775 mi.	\$28,395	Est. \$534/mo	Ed Napleton Acura Kia	21 февраля, 2025	1
Acura Certified	2023 Acura TLX Technology	22,222 mi.	\$32,790	Est. \$616/mo	Ed Napleton Acura Kia	21 февраля, 2025	1
Acura Certified	2024 Acura TLX A-Spec	7,199 mi.	\$43,811	Est. \$824/mo	Acura of Brookfield	21 февраля, 2025	1
Acura Certified	2025 Acura Integra A-Spec	1,995 mi.	\$29,979	Est. \$564/mo	Advantage Acura of Naperville	21 февраля, 2025	1
Acura Certified	2025 Acura MDX A-Spec Advance	2,557 mi.	\$59,999	Est. \$1,128/mo	Advantage Acura of Naperville	21 февраля, 2025	1
Acura Certified	2025 Acura MDX A-Spec Advance	2,901 mi.	\$63,021	Est. \$1,185/mo	McGrath Acura of Morton Grove	21 февраля, 2025	1
Aston Martin ...	2020 Aston Martin Vantage AMR PROTOTYPE	12,850 mi.	\$147,777	Est. \$2,778/mo	Napleton Aston Martin Maserati	21 февраля, 2025	1
Aston Martin ...	2021 Aston Martin DBX SUV	15,574 mi.	\$108,177	Est. \$2,033/mo	Napleton Aston Martin Maserati	21 февраля, 2025	1
Aston Martin ...	2022 Aston Martin DBS Superleggera	6,567 mi.	\$278,888	Est. \$5,242/mo	Napleton Aston Martin Maserati	21 февраля, 2025	1

Рисунок 3 – Удаление дубликатов

Очистка данных в Python

Скрипт для очистки данных на языке программирования Python представлен в Листинге 3.

Листинг 3 – Скрипт для очистки данных в Python

```
#Подсчет пустых строк
print(df.isnull().sum())
#Преобразование строковых данных в численные
import numpy as np
df['Mileage'] = df['Mileage'].apply(
    lambda x: float(x[0:-4].replace(",", ".")) if isinstance(x, str) and
x.endswith(" mi.") else np.nan
)
df['Monthly Payment'] = df['Monthly Payment'].apply(
    lambda x: float(x[6:-3].replace(",", "")) if isinstance(x, str) and
x.endswith("/mo") else np.nan
)
#Заполнение численных пропусков средним значением и медианой. А строковые новой
строкой
df['Mileage'] = df['Mileage'].fillna(df['Mileage'].mean())
df['Monthly Payment'] = df['Monthly Payment'].fillna(df['Monthly
Payment'].median())
df['Condition'] = df['Condition'].fillna("Unknown")
#Удаление дубликатов
df = df.drop_duplicates()
print("Дубликаты удалены.")
#Конечное преобразование строковых данных
df['Price (USD)'] = df['Price (USD)'].apply(
    lambda x: float(x[1:].replace(",", "")) if isinstance(x, str) and
x.startswith("$") else np.nan
)
df.head()
```

Очистка данных в R

Скрипт для очистки данных на языке программирования R представлен в Листинге 4.

Листинг 4 - Скрипт для очистки данных в R

```
library(readr)
df <- read_csv("combined_data.csv")
head(df)
#Подсчет пропусков
colSums(is.na(df))
#Удалим пропуски
df$Condition[is.na(df$Condition)] = "Unknown"
df = filter(df, !is.na(Mileage))
df = filter(df, !is.na(`Monthly Payment`))
#Удаление дубликатов
df = df[!duplicated(df), ]
print("Дубликаты удалены.")
#Преобразование типа
df$`Price (USD)` = as.numeric(gsub("[\\$,]", "", df$`Price (USD)`))
```

Сравнение подходов к очистке данных

Сравнение по критериям

1. Время выполнения операций :
 - Python: быстрое выполнение операций благодаря оптимизированным библиотекам, таким как pandas и numpy. Однако для больших объемов данных может потребоваться дополнительная оптимизация;
 - R: производительность зависит от используемых пакетов (например, dplyr, data.table). Для небольших датасетов R работает быстро, но на больших объемах данных может быть медленнее, чем Python;
 - Glarus BI: интерфейс Glarus BI позволяет выполнять операции "на лету", но при работе с большими данными производительность может снижаться из-за ограничений интерфейса.
2. Количество ручных шагов:
 - Python: требует написания кода для всех операций, что увеличивает количество ручных шагов. Однако использование скриптов позволяет автоматизировать процесс;
 - R: аналогично Python, требует написания кода;
 - Glarus BI: минимальное количество ручных шагов благодаря визуальному интерфейсу. Большинство операций выполняются через меню или перетаскивание.
3. Возможности визуализации промежуточных данных :
 - Python: визуализация возможна через библиотеки, такие как matplotlib, seaborn, но требует дополнительного кода;
 - R: превосходные возможности визуализации с использованием ggplot2 и других пакетов;
 - Glarus BI: встроенные инструменты визуализации позволяют легко просматривать промежуточные данные без написания кода.

Таблица сравнения

Сравнение различных инструментов для очистки данных представлено в табл. 1.

Таблица 1 – Сравнение методов очистки данных

Критерий	Python	R	Glarus BI
Обнаружение пропусков	Используются методы isnull(), dropna()	Функции is.na(), filter()	Автоматическое обнаружение через интерфейс
Обработка дубликатов	Используется метод drop_duplicates()	Функция duplicated()	Удаление дубликатов через группировку и фильтрацию
Преобразование типов	Используются методы astype(), to_datetime(), apply()	Функции as.numeric(), as.Date()	Преобразование типов через меню

ЗАКЛЮЧЕНИЕ

Преимущества и недостатки каждого инструмента при очистке данных

Преимущества Glarus BI

Интуитивный визуальный интерфейс, который минимизирует необходимость написания кода; быстрая загрузка и очистка данных через меню и перетаскивание; встроенные инструменты визуализации для просмотра промежуточных результатов; подходит для быстрой подготовки данных к анализу.

Недостатки Glarus BI

Ограниченная гибкость по сравнению с Python и R; производительность может снижаться при работе с большими объемами данных; меньше возможностей для сложной аналитики и автоматизации.

Преимущества Python

Высокая гибкость благодаря использованию библиотек, таких как `pandas`, `numpy` и `matplotlib`; возможность автоматизации процессов через написание скриптов; поддержка работы с большими объемами данных.

Недостатки Python

Требуется знание языка программирования и написания кода; для новичков может быть сложным из-за необходимости освоения синтаксиса и библиотек.

Преимущества R

Большое количество возможностей для статистического анализа и визуализации данных; удобные функции для обработки данных, такие как `is.na()`, `complete.cases()` и `duplicated()`; большое количество готовых решений для анализа данных.

Недостатки R

Может быть медленнее при работе с большими объемами данных по сравнению с Python; требует написания кода, что делает его менее доступным для пользователей без программистских навыков.