



МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение
высшего образования

«МИРЭА – Российский технологический университет»

РТУ МИРЭА

**Институт информационных технологий (ИИТ)
Кафедра прикладной математики (ПМ)**

**ОТЧЕТ ПО ПРАКТИЧЕСКОЙ РАБОТЕ №4
«ОПИСАТЕЛЬНАЯ
СТАТИСТИКА И ПРОВЕРКА ГИПОТЕЗ»**

по дисциплине «Языки программирования для статистической обработки
данных»

Студент группы

ИНБО-20-23. Боргачев Т.М.

(подпись)

Преподаватель

Трушин СМ

(подпись)

Москва 2025 г.

ВВЕДЕНИЕ

Цель практики: научиться рассчитывать основные статистические показатели и проводить проверку гипотез с использованием Python, R.

Задачи практики:

1. Рассчитать основные статистические показатели:

- Среднее, медиана, мода, дисперсия, стандартное отклонение.
- Python: `scipy.stats`, R: `summary`, `stats`.

2. Выполнить проверку гипотез:

- t-тест (для сравнения двух выборок).
- U-критерий Манна-Уитни (для несвязанных выборок).
- Хи-квадрат тест (для проверки независимости).

3. Сравнить результаты между Python.

РЕЗУЛЬТАТЫ РАБОТЫ

Расчёт статистических показателей в Python, R и Glarus BI

Код для расчёта статистических показателей для поля “OCD” на языке программирования Python представлен в Листинге 1.

Листинг 1 – Код для расчёта статистических показателей в Python

```
#Загрузка набора данных
import pandas as pd
df = pd.read_csv("mxmh_survey_results.csv")
import numpy as np
import scipy.stats as stats
mean_value = np.mean(df['OCD'])
median_value = np.median(df['OCD'])
mode_value = stats.mode(df['OCD'])[0]
variance = np.var(df['OCD'])
std_dev = np.std(df['OCD'])
print("Среднее:", mean_value)
print("Медиана:", median_value)
print("Мода:", mode_value)
print("Дисперсия:", variance)
print("Стандартное отклонение:", std_dev)
```

Результат расчёта статистических показателей в Python представлен на рис. 1.

```
Среднее: 2.6372282608695654
Медиана: 2.0
Мода: 0.0
Дисперсия: 8.066086882679585
Стандартное отклонение: 2.840085717488045
```

Рисунок 1 – Расчёт статистических показателей в Python

Код для расчёта статистических показателей для поля “OCD” на языке программирования R представлен в Листинге 1.

Листинг 2 – Код для расчёта статистических показателей в R

```
library(readr)
df <- read_csv("mxmh_survey_results.csv")
head(df)
install.packages("modeest")
summary(df$OCD)
# Расчёт моды
library(modeest)
mode_value <- mfv(df$OCD)
print(paste("Мода:", mode_value))
# Дисперсия и стандартное отклонение
variance <- var(df$OCD)
std_dev <- sd(df$OCD)
print(paste("Дисперсия:", OCD))
print(paste("Стандартное отклонение:", std_dev))
```

Результат расчёта статистических показателей в R представлен на рис. 2.

```
Min. 1st Qu. Median Mean 3rd Qu. Max.
0.000 0.000 2.000 2.637 5.000 10.000

[1] "Мода: 0"
[1] "Дисперсия: 8.07706115054718"
[1] "Стандартное отклонение: 2.8420170918816"
```

Рисунок 2 – Расчёт статистических показателей в R

Результат расчёта статистических показателей в Glarus BI представлен на рис. 3.




Рисунок 3 – Расчёт статистических показателей в Glarus BI

Проверка гипотез в Python, R.

Python (scipy.stats)

1. t-test представлен на рис. 4:

```
H0 = "Любимый жанр людей с повышенной тревожностью - Рок"
H1 = "Любимый жанр людей с повышенной тревожностью - не Рок, а Поп музыка"

✓ 0.0s

alpha = 0.05
group1 = df[df['Fav genre'] == 'Rock']['Anxiety']
group2 = df[df['Fav genre'] == 'Pop']['Anxiety']
t_stat, p_value = stats.ttest_ind(group1, group2)
H0_test = "Средние уровни тревожности в обеих группах равны"
H1_test = "Средние уровни тревожности в обеих группах отличаются"
print("t-статистика:", t_stat, "p-значение:", p_value)
print(H0_test if p_value>=alpha else H1_test)
print(H0 if group1.mean() > group2.mean() else H1)

✓ 0.0s

t-статистика: 0.14887645311441647 p-значение: 0.8817511467026363
Средние уровни тревожности в обеих группах равны
Любимый жанр людей с повышенной тревожностью - Рок
```

Рисунок 4 – Проверка гипотез t-test'ом в Python

2. U-Критерий Манна-Уитни представлен на рис. 5:

```
u_stat, p_value = stats.mannwhitneyu(group1, group2)
print("U-статистика:", u_stat, "p-значение:", p_value)
print(H0_test if p_value>=alpha else H1_test)
```

✓ 0.0s

U-статистика: 11329.5 p-значение: 0.4010276466322207
Средние уровни тревожности в обеих группах равны

Рисунок 5 – Проверка гипотез U-критерием в Python

3. Хи-квадрат тест представлен на рис. 6:

```
# Определение медианы уровня тревожности
anxiety_median = df['Anxiety'].median()
# Создание новой категориальной переменной
df['Anxiety_Category'] = df['Anxiety'].apply(lambda x: 'Low Anxiety' if x < anxiety_median else 'High Anxiety')
# Фильтрация датасета
filtered_df = df[df['Fav_genre'].isin(['Rock', 'Pop'])]

contingency_table = pd.crosstab(filtered_df['Fav_genre'], filtered_df['Anxiety_Category'])
```

✓ 0.0s

```
chi2_stat, p_value, dof, expected = stats.chi2_contingency(contingency_table)
print("Хи-квадрат:", chi2_stat, "p-значение:", p_value)
print(H0_test if p_value>=alpha else H1_test)
```

✓ 0.0s

Хи-квадрат: 0.08014509669428624 p-значение: 0.7771008765272718
Средние уровни тревожности в обеих группах равны

Рисунок 6 – Проверка гипотез хи-квадратом в Python

R (t.test, wilcox.test, chisq.test)

1. t-test представлен на рис. 7:

```
# Загрузка необходимых библиотек
library(dplyr)

# Гипотезы
h0 <- "Любимый жанр людей с повышенной тревожностью - Рок"
h1 <- "Любимый жанр людей с повышенной тревожностью - не Рок, а Поп музыка"
alpha <- 0.05

# Выбор групп для анализа
group1 <- df %>% filter(`Fav genre` == "Rock") %>% pull(Anxiety)
group2 <- df %>% filter(`Fav genre` == "Pop") %>% pull(Anxiety)

# Т-тест
t_test_result <- t.test(group1, group2, alternative = "two.sided")
t_stat <- t_test_result$statistic
p_value_t <- t_test_result$p.value

h0_test <- "Средние уровни тревожности в обеих группах равны"
h1_test <- "Средние уровни тревожности в обеих группах отличаются"

cat("t-статистика:", t_stat, "p-значение:", p_value_t, "\n")
if (p_value_t >= alpha) {
  cat(h0_test, "\n")
} else {
  cat(h1_test, "\n")
}

if (mean(group1) > mean(group2)) {
  cat(h0, "\n")
} else {
  cat(h1, "\n")
}

✓ 0.3s
```

Присоединяю пакет: 'dplyr'

Следующие объекты скрыты от 'package:stats':

filter, lag

Следующие объекты скрыты от 'package:base':

intersect, setdiff, setequal, union

t-статистика: 0.1556923 p-значение: 0.8763912
Средние уровни тревожности в обеих группах равны
Любимый жанр людей с повышенной тревожностью - Рок

Рисунок 7 - Проверка гипотез t-test'ом в R

2. U-Критерий Манна-Уитни представлен на рис. 8:

```
# U-критерий Манна-Уитни
u_test_result <- wilcox.test(group1, group2, alternative = "two.sided")
u_stat <- u_test_result$statistic
p_value_u <- u_test_result$p.value

cat("U-статистика:", u_stat, "p-значение:", p_value_u, "\n")
if (p_value_u >= alpha) {
  | cat(h0_test, "\n")
} else {
  | cat(h1_test, "\n")
}
~

✓ 0.0s

U-статистика: 11329.5 p-значение: 0.4010276
Средние уровни тревожности в обеих группах равны
```

Рисунок 8 – Проверка гипотез U-критерием в R

3. Хи-квадрат тест представлен на рис. 9:

```
# Хи-квадрат тест
# Определение медианы уровня тревожности
anxiety_median <- median(df$Anxiety)

# Создание новой категориальной переменной
df$Anxiety_Category <- ifelse(df$Anxiety < anxiety_median, "Low Anxiety", "High Anxiety")

# Фильтрация датасета
filtered_df <- df %>% filter(`Fav genre` %in% c("Rock", "Pop"))

# Создание таблицы сопряжённости
contingency_table <- table(filtered_df$Fav_genre, filtered_df$Anxiety_Category)

# Выполнение теста хи-квадрат
chi2_test_result <- chisq.test(contingency_table)
chi2_stat <- chi2_test_result$statistic
p_value_chi2 <- chi2_test_result$p.value

cat("Хи-квадрат:", chi2_stat, "p-значение:", p_value_chi2, "\n")
if (p_value_chi2 >= alpha) {
  | cat(h0_test, "\n")
} else {
  | cat(h1_test, "\n")
}
}

✓ 0.1s

Хи-квадрат: 0.0801451 p-значение: 0.7771009
Средние уровни тревожности в обеих группах равны
```

Рисунок 9 – Проверка гипотез Хи-квадратом в R

Сравнение результатов

Сравнение статистических данных представлено в табл. 1.

Таблица 1 – Сравнение статистических показателей

Название показателя	Python	R	Glarus BI
Среднее значение	2.6372282608695654	2.637	2.64
Медиана	2.0	2.0	2.0
Мода	0.0	0.0	---
Дисперсия	8.066086882679585	8.07706115054718	---
Стандартное отклонение	2.840085717488045	2.8420170918816	2.84

Таким образом, наиболее точные значения статистических показателей – предоставлены с помощью Python.

С учетом округления, все агрегированные значения совпали между тремя платформами, но есть разница, начиная со второго знака после запятой у дисперсии и стандартного отклонения.

Сравнение тестов гипотез представлено в табл. 2.

Таблица 2 – Сравнение гипотез

Название теста	Python (значение теста, p_value)	R (значение теста, p_value)
T-test	0.1488765, 0.881751147	0.1556923, 0.8763912
U-Критерий	11329.5, 0.4010276	11329.5, 0.4010276
Хи-квадрат	0.0801450967, 0.777100877	0.0801451, 0.7771009

Таким образом, немного отличаются только значения t-test'а между платформами. Тем не менее все p_value значительно больше 0.05, что подтверждает нулевую гипотезу.

Заключение

ЗАКЛЮЧЕНИЕ

В рамках данной практики были изучены основные методы расчета статистических показателей и проверки гипотез с использованием языков программирования Python и R. Рассмотрим ключевые результаты:

1. Расчет статистических показателей:

- Были вычислены основные статистические показатели (среднее значение, медиана, moda, дисперсия, стандартное отклонение) для поля "OCD" с помощью Python, R.
- Сравнение показало, что значения совпадают с небольшими различиями в начальных знаках после запятой. Наиболее точные результаты получены с помощью Python, однако разница не является существенной и объясняется особенностями округления в различных системах.

2. Проверка гипотез:

- Были выполнены три типа тестов: t-тест, U-критерий Манна-Уитни и хи-квадрат тест.
- Для каждого теста были получены одинаковые выводы на всех платформах: р-значения значительно превышают пороговое значение $\alpha=0.05$, что подтверждает нулевую гипотезу.
- Небольшие различия наблюдаются только в значениях t-теста между Python и R, но это не влияет на общий вывод о применимости нулевой гипотезы.

3. Сравнение результатов:

- Таблицы сравнения показывают высокое соответствие результатов между Python, R.
- Python демонстрирует наиболее точные вычисления, особенно при работе со сложными статистическими функциями.
- Однако, разница между платформами минимальна и не оказывает существенного влияния на интерпретацию результатов.

4. Общие выводы:

- Практика позволила освоить инструменты для расчета основных статистических показателей и проверки гипотез на разных платформах.
- Все используемые методы подтвердили свою надежность и согласованность результатов.
- Python и R являются мощными инструментами для статистического анализа данных, предоставляющими широкие возможности для расчётов и визуализации.

Таким образом, цель практики была успешно достигнута: мы научились

рассчитывать основные статистические показатели и проводить проверку гипотез с использованием Python, R. Результаты показали высокую согласованность между платформами и подтвердили применимость теоретических подходов к реальным данным.