



МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение
высшего образования

«МИРЭА – Российский технологический университет»

РТУ МИРЭА

**Институт информационных технологий (ИИТ)
Кафедра прикладной математики (ПМ)**

**ОТЧЕТ ПО ПРАКТИЧЕСКОЙ РАБОТЕ №6
«МНОЖЕСТВЕННАЯ**

РЕГРЕССИЯ И ОЦЕНКА КАЧЕСТВА МОДЕЛИ»

по дисциплине «Языки программирования для статистической обработки
данных»

Студент группы

ИНБО-20-23. Боргачев Т.М.

(подпись)

Преподаватель

Трушин СМ

(подпись)

Москва 2025 г.

ВВЕДЕНИЕ

Цель практики: освоить построение моделей множественной регрессии, интерпретацию их результатов и визуализацию метрик качества в Python, R.

Задачи практики:

1. Построить модели множественной регрессии:

- Выявить влияние нескольких факторов на целевую переменную.
- Python: использование statsmodels и sklearn для построения моделей.
- R: использование функции lm().

2. Оценить качество моделей:

- Рассчитать метрики R^2 и MSE для оценки качества модели.
- Python: инструменты sklearn.metrics.
- R: функции summary() и пакеты для анализа ошибок.

3. Визуализировать результаты:

- Построение графиков зависимости предсказанных значений от реальных.
- Сравнить удобство визуализации в Python и R.

4. Провести сравнительный анализ результатов, полученных в трёх инструментах.

Теоретическое введение

Множественная линейная регрессия – это модель, которая имеет следующий вид:

$$y = \beta_0 + \beta_1 \times x_1 + \beta_2 \times x_2 + \dots + \beta_k \times x_k + \varepsilon,$$

где y — зависимая переменная, $x_1, x_2, \dots, x_k$ — независимые факторы, $\beta_0, \beta_1, \dots, \beta_k$ — коэффициенты регрессии, а ε — ошибка модели.

Коэффициенты β_i показывают, насколько в среднем изменится y , если фактор x_i изменится на единицу, при этом остальные факторы остаются фиксированными.

Мультиколлинеарность: если независимые факторы сильно коррелируют между собой, регрессионная модель может стать нестабильной, а полученные коэффициенты могут быть недостоверными.

Метрики качества модели:

- R^2 (коэффициент детерминации): доля вариации зависимой переменной, объяснённая моделью.

- MSE (Mean Squared Error, среднеквадратическая ошибка): вычисляется по формуле

$$MSE = (1/n) \times \sum (y_i - \hat{y}_i)^2,$$

где y_i — фактическое значение, $\hat{y}_i$ — предсказанное значение, n — количество наблюдений.

Дополнительно часто используют:

- RMSE (Root Mean Squared Error): квадратный корень из MSE, который интерпретируется в тех же единицах, что и целевая переменная.

- MAE (Mean Absolute Error, средняя абсолютная ошибка): среднее отклонение предсказаний от фактических значений без учёта знака ошибки.

РЕЗУЛЬТАТЫ РАБОТЫ

Модели множественной регрессии

Код и результаты из Python

Код для работы с множественной регрессией в Python представлен в листинге 1.

Листинг 1 – Множественная регрессия Python

```
import pandas as pd
df = pd.read_csv("mxmh_survey_results.csv")
df_numeric = df[["Age", "Hours per day",
"BPM", "Anxiety", "Depression", "Insomnia", "OCD"]]
df.head()
import numpy as np
import statsmodels.api as sm
from sklearn.linear_model import LinearRegression
from sklearn.metrics import r2_score, mean_squared_error
import matplotlib.pyplot as plt
import statsmodels.api as sm
df[df_numeric.columns] = df_numeric.fillna(df_numeric.mean())

# Предположим, что 'OCD' — целевая переменная
# а ['Fav genre', 'Hours per day', 'Age'] — независимые факторы

X = df[['Fav genre', 'Hours per day', 'Age']]
X = pd.get_dummies(X, columns=['Fav genre'], drop_first=True)
X = X.dropna()
X = X.astype({col: 'float64' for col in X.columns if X[col].dtype == 'bool'})
Y = df['OCD']

# Добавляем константу в матрицу признаков
X = sm.add_constant(X)
# Строим модель
model_sm = sm.OLS(Y, X).fit()
print(model_sm.summary())

model_sk = LinearRegression()
model_sk.fit(X, Y)
# Коэффициенты
print("Intercept:", model_sk.intercept_)
print("Coefficients:", model_sk.coef_)
# Предсказание
y_pred = model_sk.predict(X)

r2 = r2_score(Y, y_pred)
mse = mean_squared_error(Y, y_pred)
print("R^2:", r2)
print("MSE:", mse)
#Метрики ужасные, тк там нет зависимостей в таком виде, надо использовать другого
рода модели
#Тот же лес дает r2=0.64
from sklearn.ensemble import RandomForestRegressor

rf = RandomForestRegressor(n_estimators=100, random_state=42)
rf.fit(X, Y)
print("RF R^2:", rf.score(X, Y))
```

Результаты представлены на рис. 1.

OLS Regression Results

Dep. Variable:

OCD

R-squared:

0.038

Model:

OLS

Adj. R-squared:

0.015

Method:

Least Squares

F-statistic:

1.680

Date:

Wed, 09 Apr 2025

Prob (F-statistic):

0.0416

Time:

11:28:59

Log-Likelihood:

-1798.2

No. Observations:

736

AIC:

3632.

Df Residuals:

718

BIC:

3715.

Df Model:

17

Covariance Type:

nonrobust

	coef	std err	t	P> t	[0.025	0.975]
const	2.8113	0.468	6.007	0.000	1.892	3.730
Hours per day	0.1048	0.035	2.974	0.003	0.036	0.174
Age	-0.0281	0.009	-3.079	0.002	-0.046	-0.010
Fav genre_Country	0.3020	0.684	0.441	0.659	-1.042	1.646
Fav genre_EDM	0.3262	0.608	0.536	0.592	-0.868	1.520
Fav genre_Folk	-0.2265	0.644	-0.351	0.725	-1.492	1.039
Fav genre_Gospel	-1.1649	1.244	-0.936	0.349	-3.607	1.277
Fav genre_Hip hop	0.1506	0.616	0.245	0.807	-1.058	1.359
Fav genre_Jazz	0.1345	0.745	0.180	0.857	-1.329	1.598
Fav genre_K pop	-0.1749	0.680	-0.257	0.797	-1.510	1.160
Fav genre_Latin	-1.3473	1.680	-0.802	0.423	-4.647	1.952
Fav genre_Lofi	0.7688	0.974	0.789	0.430	-1.143	2.681
Fav genre_Metal	-0.0857	0.491	-0.175	0.861	-1.050	0.878
Fav genre_Pop	0.3918	0.470	0.834	0.404	-0.530	1.314
Fav genre_R&B	0.2790	0.615	0.454	0.650	-0.928	1.486
Fav genre_Rap	0.4243	0.721	0.588	0.557	-0.992	1.840
Fav genre_Rock	0.2836	0.440	0.645	0.519	-0.580	1.147
Fav genre_Video game music	-0.1245	0.577	-0.216	0.829	-1.257	1.008

Omnibus:

75.352

Durbin-Watson:

1.854

Prob(Omnibus):

0.000

Jarque-Bera (JB):

98.110

Skew:

0.893

Prob(JB):

4.96e-22

Kurtosis:

2.902

Cond. No.

494.

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Intercept: 2.811257747770915

Coefficients: [0.10476156 -0.02805683 0.30197884 0.32617213 -0.22646987 -1.16490312 0.15056509 0.13445704 -0.17494937 -1.34733086 0.76879957 -0.08570601 0.3918141 0.27896727 0.42429306 0.28360676 -0.12447786]

R^2: 0.038249244713929764

MSE: 7.757565151620153

RF R^2: 0.645887107850576

Рисунок 1 – Метрики и параметры модели Python

Код и результаты из R

Код для работы с множественной регрессией в R представлен в листинге 2.

Листинг 2 – Множественная регрессия в R

```
library(dplyr)
library(readr)
library(stats)
# Загрузка данных
df <- read_csv("mxmh_survey_results.csv")
head(df)

# Заполнение NA в указанных числовых колонках средними значениями
cols_to_fill <- c("Age", "Hours per day", "BPM", "Anxiety", "Depression",
"Insomnia", "OCD")
df <- df %>%
  mutate(across(all_of(cols_to_fill), ~ ifelse(is.na(.), mean(., na.rm = TRUE),
.)))

# Создание датафрейма с факторами и целевой переменной
X_df <- df %>%
  select(`Fav genre`, `Hours per day`, Age, OCD) %>%
  mutate(`Fav genre` = factor(`Fav genre`)) %>%
  na.omit() # Удаление строк с NA

# Линейная регрессия с statsmodels (аналог)
model <- lm(OCD ~ `Fav genre` + `Hours per day` + Age, data = X_df)
summary(model)

# Вычисление метрик
predictions <- predict(model, X_df)
residuals <- X_df$OCD - predictions
mse <- mean(residuals^2)
r2 <- summary(model)$r.squared
print(paste("R^2:", round(r2, 4)))
print(paste("MSE:", round(mse, 4)))
```

Результаты представлены на рис. 2.

```
Call:
lm(formula = OCD ~ `Fav genre` + `Hours per day` + Age, data = X_df)

Residuals:
    Min       1Q   Median       3Q      Max
-4.1602 -2.3408 -0.7342  1.7868  7.8524

Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)      2.811258   0.467976   6.007   3e-09 ***
`Fav genre`Country  0.301979   0.684494   0.441   0.65922
`Fav genre`EDM      0.326172   0.608191   0.536   0.59192
`Fav genre`Folk     -0.226470   0.644418  -0.351   0.72537
`Fav genre`Gospel   -1.164903   1.243923  -0.936   0.34934
`Fav genre`Hip hop   0.150565   0.615760   0.245   0.80690
`Fav genre`Jazz      0.134457   0.745435   0.180   0.85691
`Fav genre`K pop    -0.174949   0.679936  -0.257   0.79702
`Fav genre`Latin    -1.347331   1.680449  -0.802   0.42295
`Fav genre`Lofi      0.768800   0.974012   0.789   0.43019
`Fav genre`Metal    -0.085706   0.491042  -0.175   0.86149
`Fav genre`Pop       0.391814   0.469602   0.834   0.40436
`Fav genre`R&B       0.278967   0.614593   0.454   0.65003
`Fav genre`Rap       0.424293   0.721306   0.588   0.55656
`Fav genre`Rock      0.283607   0.439854   0.645   0.51928
`Fav genre`Video game music -0.124478   0.576671  -0.216   0.82916
`Hours per day`      0.104762   0.035225   2.974   0.00304 **
Age                -0.028057   0.009111  -3.079   0.00215 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

[1] "R^2: 0.0382"
[1] "MSE: 7.7576"
```

Рисунок 2 – Метрики и параметры модели в R

Визуализация метрик

Визуализация метрик в Python представлена на рис. 3 и рис. 4.




Рисунок 3 – График «Сравнение реальных и предсказанных значений» в Python




Рисунок 4 – График остатков в Python

Визуализация метрик в R представлена на рис. 5 и рис. 6.




Рисунок 5 – График «Реальные vs. Предсказанные» в R




Рисунок 6 – График остатков в R

Интерпретация результатов

1. Основные метрики модели:

- R-квадрат ($R^2 = 0.038$): Модель объясняет лишь 3.8% дисперсии в зависимости (OCD), что указывает на слабую предсказательную способность. Остальные 96.2% вариации объясняются другими факторами, не учтенными в модели.
- F-статистика (1.68, $p = 0.0416$): Модель в целом статистически значима на уровне $\alpha = 0.05$, но значимость едва достигает порога, что свидетельствует о слабой совокупной значимости переменных.

2. Важные факторы:

- Hours per day (коэффициент 0.105, $p = 0.003$): Положительный значимый эффект. Каждый дополнительный час прослушивания музыки в день связан с увеличением уровня OCD на 0.105 единицы.
- Age (коэффициент -0.028, $p = 0.002$): Отрицательный значимый эффект. С

ростом возраста на один год OCD снижается на 0.028 единицы. Это может отражать возрастные особенности восприятия или изменения в поведении.

3. Любимый жанр (Fav genre):

- Коэффициенты для всех жанров не значимы ($p > 0.05$), что означает отсутствие статистически значимой связи между предпочтением конкретного жанра и уровнем OCD. Например:
 - Жанр «Gospel» имеет отрицательный коэффициент (-1.165), но его $p\text{-value} = 0.349$, что не подтверждает значимости.
 - «Lofi» и «Pop» имеют слабо положительные коэффициенты, но и они не проходят проверку значимости.

4. Среднеквадратичная ошибка ($MSE = 7.76$): Высокое значение MSE указывает на значительные расхождения между прогнозами модели и реальными данными, что согласуется с низким R^2 .

ЗАКЛЮЧЕНИЕ

Результаты анализа показывают, что среди изученных факторов (время прослушивания, возраст, любимый жанр) основное влияние на уровень OCD оказывает время ежедневного прослушивания музыки — чем больше часов, тем выше OCD. Возраст также оказывает незначительное, но значимое влияние: с возрастом уровень OCD снижается.

Однако жанр музыки не проявил статистически значимого эффекта, что может быть связано с тем, что предпочтения в жанрах не коррелируют с OCD в данном исследовании или требуют более тонкого анализа (например, учета поджанров, частоты прослушивания).

Слабая предсказательная способность модели ($R^2 = 3.8\%$) указывает на необходимость включения других переменных (например, социальных, психологических факторов, индивидуальных особенностей) для улучшения объяснительной силы. Кроме того, F-статистика едва достигает значимости, что требует осторожности в трактовке результатов и дальнейших исследований с расширенным набором данных.