



МИНОБРНАУКИ РОССИИ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«МИРЭА – Российский технологический университет»
РТУ МИРЭА

**Институт информационных технологий (ИИТ)
Кафедра прикладной математики (ПМ)**

ОТЧЕТ ПО ПРАКТИЧЕСКОЙ РАБОТЕ

по дисциплине «Прикладные задачи математической статистики»

Практическое занятие № 4

Студент группы
ИНБО-20-23

Боргачев Т.М.

(подпись)

Ассистент

Трушина В.И.

(подпись)

Отчет представлен «24».10.2025 г.

Москва 2025 г.

СОДЕРЖАНИЕ

1 ГЕНЕРАЦИЯ РАСПРЕДЕЛЕНИЙ.....	3
1.1 Постановка задачи.....	3
1.2 Ход работы.....	4
1.2.1 Генерация выборки распределения Гаусса.....	4
1.2.2 Генерация выборки распределения Пирсона	7
1.2.3 Генерация выборки распределения Фишера	9
1.2.4 Генерация выборки распределения Стьюдента	11
ВЫВОД.....	14

1 ГЕНЕРАЦИЯ РАСПРЕДЕЛЕНИЙ

1.1 Постановка задачи

Для выполнения практического задания необходимо:

1. Используя определение центральной предельной теоремы. На основе $k = 20 - 30$ равномерно распределенных реализаций случайных величин образовать новую выборку по определению центральной предельной теоремы.
2. Для получившейся выборки построить гистограмму, визуализировать на гистограмме теоретическую плотность нормального распределения по несмещенным точечным оценкам и провести тест на нормальное распределение с помощью критерия χ^2 — Пирсона (степени свободы рассчитывать как $df = m - 3$) и методом анаморфоз.
3. Определить влияние числа сгенерированных равномерно распределенных величин на итоговое качество генерации нормального распределения при помощи взятия 3 тестовых генераций при разных k и проведения теста на распределение.
4. Сгенерировать выборку распределения Фишера на основе определения. На основе двух случайных реализаций Y_1, Y_2 случайных величин, распределенных по χ^2 -распределению со степенями свободами d_1, d_2 соответственно. Сгенерировать выборку, распределенную по распределению Фишера.
5. Сгенерировать выборку t -распределения на основе определения. На основе $k \approx 2 - 9$ случайных реализаций $Y_1, Y_2, \dots, Y_k$ случайных величин, распределенных по стандартному нормальному распределению, сгенерировать выборку $T \sim t(k)$, распределенную по t -

распределению Стьюдента с $df=k$ степенями свободы в соответствии с определением.

6. Для получившейся выборки построить гистограмму, визуализировать на гистограмме теоретическую плотность $t(k)$. Для получившейся выборки провести тест на t -распределение Стьюдента с помощью критерия χ^2 — Пирсона.

1.2 Ход работы

1.2.1 Генерация выборки распределения Гаусса

Согласно центральной предельной теореме (ЦПТ), сумма большого числа независимых одинаково распределённых случайных величин стремится к нормальному распределению. В работе используется следующая конструкция:

$$Y = \sum_{i=1}^k X_i, \quad X_i \sim U(a_i, b_i),$$

где X_i — равномерно распределенная реализация случайной величины со случайными параметрами a_i, b_i .

Возьмем $a = 0, b = 1$. Сформируем гипотезы

- H_0 : выборка соответствует нормальному распределению;
- H_1 : выборка не соответствует нормальному распределению.

Скрипт для генерации выборки распределения Гаусса представлен в Листинге 1.

Листинг 1 — Генерация выборки распределения Гаусса

```
import numpy as np
import matplotlib.pyplot as plt
import scipy.stats as stats
```

Продолжение Листинга 1

```
from scipy.stats import chi2, norm, f, t

def chi2_goodness_of_fit(data, dist, params, alpha=0.05):
    n = len(data)
    # Определим число интервалов по правилу Стёржесса
    m = int(np.log2(n)) + 1
    if m < 5:
        m = 5
    # Гистограмма
    counts, bin_edges = np.histogram(data, bins=m)
    bin_centers = (bin_edges[:-1] + bin_edges[1:]) / 2
    expected = []
    for i in range(m):
        p = dist.cdf(bin_edges[i+1], *params) -
dist.cdf(bin_edges[i], *params)
        expected.append(n * p)
    expected = np.array(expected)

    while np.any(expected < 5):
        idx = np.argmin(expected)
        if idx == 0:
            expected[1] += expected[0]
            counts[1] += counts[0]
            expected = np.delete(expected, 0)
            counts = np.delete(counts, 0)
        elif idx == len(expected) - 1:
            expected[-2] += expected[-1]
            counts[-2] += counts[-1]
            expected = np.delete(expected, -1)
            counts = np.delete(counts, -1)
        else:
            if expected[idx-1] < expected[idx+1]:
                expected[idx-1] += expected[idx]
                counts[idx-1] += counts[idx]
                expected = np.delete(expected, idx)
                counts = np.delete(counts, idx)
            else:
                expected[idx+1] += expected[idx]
                counts[idx+1] += counts[idx]
                expected = np.delete(expected, idx)
                counts = np.delete(counts, idx)

    # Статистика хи-квадрат
    chi2_stat = np.sum((counts - expected)**2 / expected)
    df = len(expected) - 1 - len(params)
    p_value = 1 - chi2.cdf(chi2_stat, df)
    reject = p_value < alpha
    return chi2_stat, df, p_value, reject

np.random.seed(42)
n = 1000
k_vals = [1, 5, 10]
```

Продолжение Листинга 1

```
results_gauss = {}
for k in k_vals:
    X = np.random.uniform(0, 1, size=(n, k))
    Y = X.sum(axis=1)
    mu_hat = np.mean(Y)
    sigma_hat = np.std(Y, ddof=1)

    chi2_stat, df, p_val, reject = chi2_goodness_of_fit(Y, norm,
(mu_hat, sigma_hat))

    qq = stats.probplot(Y, dist="norm", sparams=(mu_hat,
sigma_hat))
    results_gauss[k] = {
        'data': Y,
        'mu': mu_hat,
        'sigma': sigma_hat,
        'chi2': chi2_stat,
        'df': df,
        'p': p_val,
        'reject': reject,
        'qq': qq
    }
```

Статистики, рассчитанные для $k = 1, 5, 10$ представлены в Таблице 1.

Таблица 1 — Статистики для распределения Гаусса

Статистика	k=1	k=5	k=10
Мат ожидание	0.5	2.5	5
Стандартное отклонение	0.2921	0.6343	0.876
р-значение теста хи-квадрат	0	0.1	0.44
Принятая гипотеза	H1	H0	H0

Графики плотностей распределения и проверка распределения методом анаморфоз представлены на Рисунке 1.




Рисунок 1 — Плотности распределения выборок

Таким образом, при $k=1$ распределение равномерное и при увеличении k стремится к нормальному так, что начиная с $k=5$ принимается нулевая гипотеза. Несмотря на S-образность прямой при $k=1$, она довольно сильно похожа на прямую на большом промежутке, в следствие чего метод анаморфоз дает ложно положительный результат ($R^2 > 0.95$).

1.2.2 Генерация выборки распределения Пирсона

Определение: если $Z_1, \dots, Z_k \sim N(0,1)$, то

$$X = \sum_{i=1}^k Z_i^2 \sim \chi^2(k),$$

где Z_i — i -я независимая случайная величина, имеющая стандартное

нормальное распределение с математическим ожиданием 0 и дисперсией 1;

$\chi^2(k)$ — распределение пирсона с k степенями свободы.

Возьмем $k = 5$. Сформируем гипотезы:

- H_0 : выборка соответствует распределению Пирсона;
- H_1 : выборка не соответствует распределению Пирсона.

Скрипт для генерации выборки распределения Пирсона представлен в Листинге 2.

Листинг 2 — Генерация выборки распределения Пирсона

```
k_df = 5 # степени свободы
n = 1000

Z = np.random.normal(0, 1, size=(n, k_df))
chi2_sample = np.sum(Z**2, axis=1)

df_est = np.mean(chi2_sample)

m = int(np.log2(n)) + 1 # правило Стержесса

plt.figure(figsize=(12, 4))
plt.subplot(1, 2, 1)
plt.hist(chi2_sample, bins=m, density=True, alpha=0.6)
x = np.linspace(0, chi2_sample.max(), 200)
plt.plot(x, stats.chi2.pdf(x, df=k_df), 'r-', lw=2)
plt.title(f' $\chi^2$ -распределение (k={k_df})')
plt.subplot(1, 2, 2)
stats.probplot(chi2_sample, dist=stats.chi2, sparams=(k_df,),
plot=plt)
plt.title('Метод анаморфоз')
plt.show()

observed, bins = np.histogram(chi2_sample, bins=m)
expected = n * np.diff(stats.chi2.cdf(bins, df=k_df))
expected = expected * (observed.sum() / expected.sum())
chi2_stat, p = stats.chisquare(observed, expected)
print(f" $\chi^2$ -тест: статистика={chi2_stat:.2f}, p={p:.3f}")
print(f" $H_0$  {'отвергается' if p < 0.05 else 'не отвергается'}")
osm, osr = stats.probplot(chi2_sample, dist=stats.chi2,
sparams=(k_df,), fit=False)
print(f" $R^2 = \{r2\_score(osm, osr)\}$ ")
```

Графики плотностей распределения и проверка распределения методом анаморфоз представлены на Рисунке 2.




Рисунок 2 — Плотность распределения и метод анаморфоз распределения Пирсона

Статистики, рассчитанные для $k = 5$:

1. χ^2 -тест: статистика=3.34, $p=0.949$.
2. H_0 не отвергается.
3. $R^2 = 0.9963219586555802$.

Таким образом, при $k=5$ распределение имеет тяжелый левый хвост, что отличает его от нормального и соответствует распределению Пирсона.

1.2.3 Генерация выборки распределения Фишера

Определение: если $U \sim \chi^2(d_1), V \sim \chi^2(d_2)$, то

$$F = \frac{U / d_1}{V / d_2} \sim F(d_1, d_2),$$

где F — случайная величина, имеющая распределение Фишера;

U, V — случайные величины, имеющие распределение Пирсона;

d_1, d_2 — степени свободы.

Возьмем $d_1 = 6, d_2 = 12$. Сформируем гипотезы

- H_0 : выборка соответствует распределению Фишера;

- H1: выборка не соответствует распределению Фишера.

Скрипт для генерации выборки распределения Фишера представлен в Листинге 3.

Листинг 3 — Генерация выборки распределения Фишера

```
d1, d2 = 6, 12
n = 1000
np.random.seed(42)
U = np.sum(np.random.normal(0,1,size=(n,d1))**2, axis=1)
V = np.sum(np.random.normal(0,1,size=(n,d2))**2, axis=1)
m = int(np.log2(n)) + 1
F_sample = (U / d1) / (V / d2)

# Визуализация
plt.figure(figsize=(12, 4))
plt.subplot(1, 2, 1)
plt.hist(F_sample, bins=m, density=True, alpha=0.6)
x = np.linspace(0, np.percentile(F_sample, 99), 200)
plt.plot(x, stats.f.pdf(x, d1, d2), 'r-', lw=2)
plt.title(f'F-распределение (d1={d1}, d2={d2})')
plt.subplot(1, 2, 2)
stats.probplot(F_sample, dist=stats.f, sparams=(d1, d2), plot=plt)
plt.title('Q-Q plot F')
plt.show()

#  $\chi^2$ -тест
observed, bins = np.histogram(F_sample, bins=m)
expected = n * np.diff(stats.f.cdf(bins, d1, d2))
expected = expected * (observed.sum() / expected.sum())
chi2_stat, p = stats.chisquare(observed, expected)
print(f"F-тест:  $\chi^2$ ={chi2_stat:.2f}, p={p:.3f}, H0 {'отвергается' if p < 0.05 else 'не отвергается'})
osm, osr = stats.probplot(chi2_sample, dist=stats.chi2,
sparams=(k_df,), fit=False)
print(f"R2 = {r2_score(osm, osr)}")
```

Графики плотностей распределения и проверка распределения методом анаморфоз представлены на Рисунке 3.




Рисунок 3 — График плотности распределения Фишера и метода анморфоз

Рассчитанные статистики:

F-тест: $\chi^2=13.18$, $p=0.155$, H_0 не отвергается, $R^2 = 0.9977003709634743$.

Таким образом, сгенерированная выборка при $d1=6$, $d2=12$ соответствует F-распределению: гистограмма согласуется с теоретической плотностью, Q–Q-график близок к прямой ($R^2 \approx 0.998$), а p-значение χ^2 -теста (0.155) не позволяет отвергнуть нулевую гипотезу.

1.2.4 Генерация выборки распределения Стьюдента

Определение: если $Z \sim N(0,1)$, $V \sim \chi^2(k)$, то

$$T = \frac{Z}{\sqrt{V/k}} \sim t(k),$$

где Z — случайная величина, имеющая стандартное нормальное распределение;

V — случайная величина, имеющая распределение Пирсона с k степенями свободы;

$t(k)$ — распределение Стьюдента с k степенями свободы.

Возьмем $a = 0$, $b = 1$. Сформируем гипотезы

- H_0 : выборка соответствует распределению Стьюдента;
- H_1 : выборка не соответствует распределению Стьюдента.

Скрипт для генерации выборки распределения Стьюдента представлен в Листинге 4.

Листинг 4 — Генерация выборки распределения Стьюдента

```
k = 9
n = 1000

Z = np.random.normal(0, 1, n)
V = np.sum(np.random.normal(0,1,size=(n,k))**2, axis=1)
T_sample = Z / np.sqrt(V / k)
m = int(np.log2(n)) + 1
# Визуализация
plt.figure(figsize=(12, 4))
plt.subplot(1, 2, 1)
plt.hist(T_sample, bins=m, density=True, alpha=0.6)
x = np.linspace(-4, 4, 200)
plt.plot(x, stats.t.pdf(x, df=k), 'r-', lw=2)
plt.title(f't-распределение (k={k})')
plt.subplot(1, 2, 2)
stats.probplot(T_sample, dist=stats.t, sparams=(k,), plot=plt)
plt.title('Q-Q plot t')
plt.show()

#  $\chi^2$ -тест
observed, bins = np.histogram(T_sample, bins=m)
expected = n * np.diff(stats.t.cdf(bins, df=k))
expected = expected * (observed.sum() / expected.sum())
chi2_stat, p = stats.chisquare(observed, expected)
print(f"t-тест:  $\chi^2$ ={{chi2_stat:.2f}}, p={{p:.3f}},  $H_0$  {'отвергается'
if p < 0.05 else 'не отвергается'})")
```

Графики плотностей распределения и проверка распределения методом анаморфоз представлены на Рисунке 4.




Рисунок 4 — График плотности t-распределения и метод анаморфоз

Рассчитанные статистики: t-тест: $\chi^2=7.40$, $p=0.595$, H_0 не отвергается.

Таким образом, при $k=9$ выборка, построенная по определению через нормальную и χ^2 -величины, соответствует t-распределению: гистограмма и теоретическая плотность совпадают, Q–Q-график почти линейный, а p-значение χ^2 -теста (0.595) подтверждает принятие нулевой гипотезы.

ВЫВОД

В ходе практической работы были успешно реализованы методы генерации различных вероятностных распределений на основе фундаментальных теоретических определений: нормального распределения — через центральную предельную теорему, χ^2 -, F- и t-распределений — через преобразования нормальных случайных величин. Проведённые статистические тесты (критерий χ^2 и Q–Q-анализ) подтвердили корректность генерации: для всех рассмотренных случаев нулевые гипотезы о соответствии теоретическим распределениям не были отвергнуты. Особое внимание было уделено влиянию параметра k (числа суммируемых равномерных величин) на качество аппроксимации нормального распределения — показано, что уже при $k=5$ распределение становится близким к нормальному. Работа продемонстрировала эффективность применения как визуальных, так и формальных статистических методов для идентификации распределений и подтвердила практическую значимость теоретических положений математической статистики.