



МИНОБРНАУКИ РОССИИ

**Федеральное государственное бюджетное образовательное учреждение
высшего образования**

«МИРЭА – Российский технологический университет»

РТУ МИРЭА

**Институт информационных технологий (ИИТ)
Кафедра прикладной математики (ПМ)**

ОТЧЕТ ПО ПРАКТИЧЕСКОЙ РАБОТЕ №1
по дисциплине «Системы управления большими данными»

Студент группы *ИНБО-20-23. Боргачев Т.М.*

(подпись)

Преподаватель *Трушин СМ*

(подпись)

Москва 2025 г.


СОДЕРЖАНИЕ

1 РАБОТА С HADOOP	3
1.1 Запуск служб Hadoop — HDFS и YARN	3
1.2 Работа с домашними каталогами Linux и HDFS.....	3
2 ИЗУЧЕНИЕ И РАБОТА С КАТАЛОГАМИ HDFS.....	6
2.1 Исследование HDFS с помощью веб-интерфейса	6
3 РАБОТА С YARN/MAPREDUCE	12
3.1 YARN historyserver	12
4 САМОСТОЯТЕЛЬНАЯ РАБОТА	14
4.1 Работа с HDFS	14
4.2 Создание пользователей и прав	15
4.3 Исследование блоков HDFS.....	16
4.4 Работа с MapReduce	17
4.5 Мониторинг YARN	19
4.6 Исследование репликации	19
ВЫВОД.....	21

1 РАБОТА С HADOOP

1.1 Запуск служб Hadoop — HDFS и YARN

Процесс запуска служб HDFS и YARN из-под учетной записи `hadoop` представлен на Рисунке 1.



```
[root@osboxes ~]# su - hadoop
Last login: Fri Sep  5 05:39:08 EDT 2025 on pts/1
[hadoop@osboxes ~]$ cd ~/hadoop/sbin
[hadoop@osboxes sbin]$ ./start-dfs.sh
starting namenodes on [localhost]
starting datanodes
starting secondary namenodes [osboxes.org]
[hadoop@osboxes sbin]$ ./start-yarn.sh
starting resourcemanager
starting nodemanagers
[hadoop@osboxes sbin]$ |
```

Рисунок 1 — Запуск служб `hadoop`

Демоны `resourcemanager` и `nodemanagers` для сервисов YARN успешно запущены.

1.2 Работа с домашними каталогами Linux и HDFS

Исследование каталогов HDFS представлено на Рисунке 2.

```

[root@osboxes ~]# hdfs dfs -ls /
Found 2 items
drwxrwxrwx   - hadoop supergroup          0 2025-09-02 03:52 /tmp
drwxr-xr-x   - hadoop supergroup          0 2025-09-02 03:52 /user
[root@osboxes ~]# hdfs dfs -ls /user
/user/studenFound 1 items
drwxr-xr-x   - student student            0 2025-09-02 03:52 /user/student
[root@osboxes ~]# hdfs dfs -ls /user/root
ls: '/user/root': No such file or directory
[root@osboxes ~]# hdfs dfs -ls /user/student
[root@osboxes ~]# cd /home
[root@osboxes home]# ls -l
total 8
drwx-----. 19 hadoop  hadoop  4096 Sep  2 03:53 hadoop
drwx-----.  3 test   users   78 May 31 07:03 home_dir_test
drwx-----.  6 kafka  kafka   157 Sep  4 08:55 kafka
drwx-----. 16 osboxes osboxes 4096 Sep 29 07:06 osboxes
[root@osboxes home]# cd /home/student
-bash: cd: /home/student: No such file or directory
[root@osboxes home]# ls -l
total 8
drwx-----. 19 hadoop  hadoop  4096 Sep  2 03:53 hadoop
drwx-----.  3 test   users   78 May 31 07:03 home_dir_test
drwx-----.  6 kafka  kafka   157 Sep  4 08:55 kafka
drwx-----. 16 osboxes osboxes 4096 Sep 29 07:06 osboxes
[root@osboxes home]# cd /home/

```

Рисунок 2 — Исследование каталогов

Процесс добавления пользователя student2 представлен на Рисунке 3.

```

[root@osboxes home]# sudo useradd student2 -m
[root@osboxes home]# sudo passwd student2
Changing password for user student2.
New password:
BAD PASSWORD: The password contains the user name in some form
Retype new password:
Sorry, passwords do not match.
New password:
BAD PASSWORD: The password contains the user name in some form
Retype new password:
passwd: all authentication tokens updated successfully.

```

Рисунок 3 — Процесс добавления пользователя в Linux

Добавление пользователя в группу и создание директории представлены на Рисунке 4.

```

[root@osboxes home]# sudo usermod -aG wheel student2
[root@osboxes home]# su - student2
su: user - does not exist
[root@osboxes home]# su - student2
[student2@osboxes ~]$ d
bash: d: command not found...
[student2@osboxes ~]$ ls -l
total 0
[student2@osboxes ~]$ pwd
/home/student2
[student2@osboxes ~]$ groups
student2 wheel
[student2@osboxes ~]$ mkdir HDFS
[student2@osboxes ~]$ |

```

Рисунок 4 — Добавление пользователя в группу wheel

Создание домашнего каталога hdfs для пользователя student2 представлено на Рисунке 5.

```

[root@osboxes ~]# su - hadoop
Last login: Mon Sep 29 09:10:50 EDT 2025 on pts/2
[hadoop@osboxes ~]$ hdfs dfs -ls /user/student2
[hadoop@osboxes ~]$ hdfs dfs -mkdir /user/student2
dfs dfs -chown student2 /user/student2
mkdir: `/user/student2': File exists
[hadoop@osboxes ~]$ hdfs dfs -chown student2 /user/student2

[hadoop@osboxes ~]$
[hadoop@osboxes ~]$ hdfs dfs -ls /user/student2
[hadoop@osboxes ~]$ |

```

Рисунок 5 — Создание домашнего каталога

Перейдем к работе с каталогами.

2 ИЗУЧЕНИЕ И РАБОТА С КАТАЛОГАМИ HDFS

Просмотр файла с помощью команды `less` представлен на Рисунке 6.

```
Alice was beginning to get very tired of sitting by her sister on the bank,
and of having nothing to do: once or twice she had peeped into the book her sister was reading,
but it had no pictures or conversations in it, 'and what is the use of a book,' thought Alice
'without pictures or conversations?'
alice_in_wonderland.txt (END)
```

Рисунок 6 — Результат команды `less`

Использование команды `put` представлено на Рисунке 7.

```
[student2@osboxes data]$ hdfs dfs -put \
> /home/student2/data/alice_in_wonderland.txt \
> /user/student2/MRtest/
[student2@osboxes data]$ |
[student2@osboxes data]$ hdfs dfs -ls /user/student2/MRtest
Found 1 items
-rw-r--r-- 1 student2 student2      305 2025-09-29 09:50 /user/student2/MRtest/alice_in_wonderland.txt
[student2@osboxes data]$ |
```

Рисунок 7 — Команда `put`

Перейдем к веб-интерфейсу.

2.1 Исследование HDFS с помощью веб-интерфейса

Вкладка `overview` веб-интерфейса `hadoop` представлена на Рисунке 8.

The screenshot shows the Hadoop Overview page in a web browser. The page has a green header with tabs for Hadoop, Overview, Datanodes, Datanode Volume Failures, Snapshot, Startup Progress, and Utilities. The Overview tab is selected, showing the status of the Hadoop cluster on localhost:9000.

Overview 'localhost:9000' (✓active)

Started:	Mon Sep 29 18:04:26 +0300 2025
Version:	3.3.1, ra3b9c37a397ad4188041d80621bdeefc46885f2
Compiled:	Tue Jun 15 08:13:00 +0300 2021 by ubuntu from (HEAD detached at release-3.3.1-RC3)
Cluster ID:	CID-8ccfc08e-ca5b-406b-679f-2443709d1f3c
Block Pool ID:	BP-2077243428-50.16.218.27-1756798802245

Summary

Security is off.
SafeMode is off.
7 files and directories, 1 blocks (1 replicated blocks, 0 erasure coded block groups) = 8 total filesystem object(s).
Heap Memory used 160.1 MB of 269.5 MB Heap Memory. Max Heap Memory is 1.83 GB.
Non Heap Memory used 52.03 MB of 53.38 MB Committed Non Heap Memory. Max Non Heap Memory is <unbounded>.

Configured Capacity:	254.87 GB
Configured Remote Capacity:	0 B
DFS Used:	16 KB (0%)
Non DFS Used:	1.64 GB
DFS Remaining:	253.23 GB (99.36%)
Block Pool Used:	16 KB (0%)
DataNodes usages% (Min/Median/Max/stdDev):	0.00% / 0.00% / 0.00% / 0.00%
Live Nodes	1 (Decommissioned: 0, In Maintenance: 0)
Dead Nodes	0 (Decommissioned: 0, In Maintenance: 0)
Decommissioning Nodes	0
Entering Maintenance Nodes	0

Рисунок 8 — Вкладка `overview`

Вкладка datanode веб-интерфейса hadoop представлена на Рисунке 9.




Рисунок 9 — Вкладка datanode

Вкладка datanode volume failure веб-интерфейса hadoop представлена на Рисунке 10.




Рисунок 10 — Вкладка datanode volume failure

Вкладка snapshot веб-интерфейса hadoop представлена на Рисунке 11.

Hadoop

Overview

Datanodes

Datanode Volume Failures

Snapshot

Startup Progress

Utilities ▾

Snapshot Summary

Snapshottable directories: 0

Path	Snapshot Number	Snapshot Quota	Modification Time	Permission	Owner	Group
------	-----------------	----------------	-------------------	------------	-------	-------

Snapshots: 0

Snapshot ID	Snapshot Directory	Modification Time
-------------	--------------------	-------------------

Hadoop, 2021.

Рисунок 11 — Вкладка snapshot

Вкладка startup progress веб-интерфейса hadoop представлена на Рисунке 12.

Hadoop	Overview	Datanodes	Datanode Volume Failures	Snapshot	Startup Progress	Utilities ▾
Startup Progress						
Elapsed Time: 0 sec, Percent Complete: 100%						
Phase					Completion	Elapsed Time
Loading fsimage /home/hadoop/hadoopdata/hdfs/namenode/current/fsimage_0000000000000000037 895 B					100%	0 sec
erasure coding policies (0/0)					100%	
inodes (7/7)					100%	
delegation tokens (0/0)					100%	
cache pools (0/0)					100%	
Loading edits					100%	0 sec
/home/hadoop/hadoopdata/hdfs/namenode/current/edits_0000000000000000038-0000000000000000038 1 MB (1/1)					100%	
Saving checkpoint					100%	0 sec
Safe mode					100%	0 sec
awaiting reported blocks (0/1)					100%	
Hadoop, 2021.						

Рисунок 12 — Вкладка startup progress

Созданные и настроенные edits и fsimages представлены на Рисунке 13.


```

Last login: Mon Sep 29 11:04:08 EDT 2025 on pts/0
[root@osboxes ~]# su - hadoop
[hadoop@osboxes ~]$ cd /home/hadoop/hadoopdata/hdfs/namenode/current/
[hadoop@osboxes current]$ ls
edits_00000000000000000001-00000000000000000001  edits_00000000000000000023-00000000000000000024
edits_00000000000000000002-00000000000000000002  edits_00000000000000000025-00000000000000000036
edits_00000000000000000003-00000000000000000008  edits_00000000000000000037-00000000000000000037
edits_00000000000000000009-00000000000000000010  edits_00000000000000000038-00000000000000000038
edits_00000000000000000011-00000000000000000012  edits_inprogress_00000000000000000039
edits_00000000000000000013-00000000000000000014  fsimage_00000000000000000036
edits_00000000000000000015-00000000000000000016  fsimage_00000000000000000036.md5
edits_00000000000000000017-00000000000000000018  fsimage_00000000000000000037
edits_00000000000000000019-00000000000000000019  fsimage_00000000000000000037.md5
edits_00000000000000000020-00000000000000000021  seen_txid
edits_00000000000000000022-00000000000000000022  VERSION
[hadoop@osboxes current]$

```

Рисунок 13 — Образы и эдиты

Местоположение скопированного файла в веб-интерфейсе представлено на Рисунке 14.

The screenshot shows the Hadoop web interface with the 'Browse Directory' page. The path '/user/student2/MRtest' is entered in the search bar. A table lists the contents of the directory, showing a single file named 'alice_in_wonderland.txt' with a size of 305 B. The interface includes navigation tabs at the top and a search bar on the right.

Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
-rw-f--f--	student2	student2	305 B	Sep 29 16:50	1	128 MB	alice_in_wonderland.txt

Рисунок 14 — Местоположение скопированного файла

Информация о файле представлена на Рисунке 15.

[Download](#)[Head the file \(first 32K\)](#)[Tail the file \(last 32K\)](#)

Block information -- Block 0 ▾

Block 0

Block ID: 1073741825

Block Pool ID: BP-2077243428-50.16.218.27-1756798802245

Generation Stamp: 1001

Size: 305

Availability:

- localhost

Close

Рисунок 15 — Информация о файле

Block ID: 1073741825, Block Pool ID: BP-2077243428-50.16.218.27-1756798802245.

Поиск действительного расположения блока в Linux представлен на Рисунке 16.

```
[root@osboxes ~]# su - hadoop
Last login: Tue Sep 30 09:19:21 EDT 2025 on pts/1
[hadoop@osboxes ~]$ sudo find / -name BP-2077243428-50.16.218.27-1756798802245 -print
[sudo] password for hadoop:
/home/hadoop/hadoopdata/hdfs/datanode/current/BP-2077243428-50.16.218.27-1756798802245
find: '/proc/8190': No such file or directory
find: '/run/user/1000/gvfs': Permission denied
[hadoop@osboxes ~]$ |
```

Рисунок 16 — Местоположение блока в ОС

Просмотр содержимого файла из блока представлен на Рисунке 17.

```

hadoop@osboxes ~]$ sudo cd /run/user/1000/
hadoop@osboxes ~]$ ls
Desktop Documents Downloads hadoop hadoopdata Music Pictures Public Templates Videos
hadoop@osboxes ~]$ sudo find . -name 1073741825 -print
hadoop@osboxes ~]$ sudo find . -name *1073741825* -print
./hadoopdata/hdfs/datanode/current/BP-2077243428-50.16.218.27-1756798802245/current/finalized/subdir0/subdir0/blk_1073741825_1001.meta
./hadoopdata/hdfs/datanode/current/BP-2077243428-50.16.218.27-1756798802245/current/finalized/subdir0/subdir0/blk_1073741825
hadoop@osboxes ~]$ cat ./hadoopdata/hdfs/datanode/current/BP-2077243428-50.16.218.27-1756798802245/current/finalized/subdir0/subdir0/blk_1073741825
Alice was beginning to get very tired of sitting by her sister on the bank,
and of having nothing to do: once or twice she had peeped into the book her sister was reading,
but it had no pictures or conversations in it, 'and what is the use of a book,' thought Alice
without pictures or conversations?'[hadoop@osboxes ~]$

```

Рисунок 17 — Поиск и просмотр содержимого файла

Перейдем к работе с YARN.

3 РАБОТА С YARN/MAPREDUCE

3.1 YARN historyserver

Запуск historyserver представлен на Рисунке 18.

```
[hadoop@osboxes sbin]$ mr-jobhistory-daemon.sh start historyserver
WARNING: Use of this script to start the MR JobHistory daemon is deprecated.
WARNING: Attempting to execute replacement "mapred --daemon start" instead.
[hadoop@osboxes sbin]$
```

Рисунок 18 — Запуск historyserver

Запуск приложения подсчета слов представлен на Рисунке 19.

```
[hadoop@osboxes mapreduce]$ su - student2
Password:
Last login: Tue Sep 30 10:00:13 EDT 2025 on pts/1
[hadoop@osboxes ~]$ hadoop jar ./hadoop-mapreduce-examples-3.3.1.jar wordcount MRtest WC_output
JAR does not exist or is not a normal file: /home/student2/hadoop-mapreduce-examples-3.3.1.jar
[hadoop@osboxes ~]$ cd /home/student2/hadoop-mapreduce
[hadoop@osboxes mapreduce]$ hadoop jar ./hadoop-mapreduce-examples-3.3.1.jar wordcount MRtest WC_Output
2025-09-30 10:01:51.179 INFO Client.DefaultNOHARMAFollowerProxyProvider: Connecting to ResourceManager at /0.0.0.0:8032
2025-09-30 10:01:51.544 INFO mapreduce.JobResourceUploader: Disabling Erasure Coding for path: /tmp/hadoop-yarn/staging/student2/.staging/job_1759158280113_0011
2025-09-30 10:01:51.786 INFO input.FileInputFormat: Total input files to process : 1
2025-09-30 10:01:52.688 INFO mapreduce.JobSubmitter: number of splits:1
2025-09-30 10:01:53.464 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_1759158280113_0011
2025-09-30 10:01:53.464 INFO mapreduce.JobSubmitter: Executing with tokens: []
2025-09-30 10:01:53.995 INFO conf.Configuration: resource-types.xml not found
2025-09-30 10:01:53.995 INFO resource.ResourceUtils: Unable to find 'resource-types.xml'.
2025-09-30 10:01:54.775 INFO impl.YarnClientImpl: Submitted application: job_1759158280113_0011
2025-09-30 10:01:54.826 INFO mapreduce.Job: The url to track the job: http://localhost:8088/proxy/application_1759158280113_0011/
2025-09-30 10:01:54.827 INFO mapreduce.Job: Running job: job_1759158280113_0011
```

Рисунок 19 — Запуск MapReduce

Запущенные приложения в hadoop представлены на Рисунке 20.

The screenshot displays the 'All Applications' page of a Hadoop cluster. The top section provides a summary of cluster metrics, including the number of submitted, pending, running, and completed applications, as well as resource usage. Below this, there's a detailed view of active nodes and their resources. The 'Scheduler Metrics' section shows the current state of the scheduler, including the number of submitted and pending jobs. The bottom section is a table of application jobs, with the first job 'hadoop-17815820111-001' shown in a 'SUCCEEDED' state.

ID	User	Name	Application Type	Queue	Application Priority	Start Time	Launch Time	Finish Time	State	Final Status	Running Containers	Allocated CPU Cores	Allocated Memory MB	Allocated GPUs	Reserved CPU Cores	Reserved Memory MB	Reserved GPUs	% of Cores	% of Cluster	Progress	Tracking	Blacklisted Nodes
hadoop-17815820111-001	student	word count	MAPREDUCE	default	0	Tue Sep 30 17:01:54 +0000 2020	Tue Sep 30 17:01:56 +0000 2020	Tue Sep 30 17:02:00 +0000 2020	FINISHED	SUCCEEDED	NA	NA	NA	NA	NA	NA	NA	0.0	0.0			

Рисунок 20 — Приложения hadoop

Application master представлен на Рисунке 21.

4 САМОСТОЯТЕЛЬНАЯ РАБОТА

4.1 Работа с HDFS

Создание директории `test_data` представлено на Рисунке 24.

```
[student2@osboxes ~]$ hdfs dfs -mkdir -p /user/student2/test_data
[student2@osboxes ~]$ |
```

Рисунок 24 — Создание директории `test_data`

Процесс копирования файла `sample_data` из `data` в `test_data` представлен на Рисунке 25.

```
[student2@osboxes ~]$ hdfs dfs -mkdir -p /user/student2/test_data
[student2@osboxes ~]$ ls -la /home/student2/data/
total 64
drwxr-xr-x.  2 student2 hadoop    255 Sep 29 09:48 .
drwx----- 17 student2 student2 4096 Sep 29 10:46 ..
-rw-rw-r--.  1 student2 student2  305 Sep 29 09:47 alice_in_wonderland.txt
-rw-rw-r--.  1 student2 student2  598 Sep 29 09:47 authors.csv
-rw-rw-r--.  1 student2 student2  646 Sep 29 09:47 authors_export.sql
-rw-rw-r--.  1 student2 student2 18400 Sep 29 09:47 big_text.txt
-rw-rw-r--.  1 student2 student2  2747 Sep 29 09:47 labs_init.sql
-rw-rw-r--.  1 student2 student2  1712 Sep 29 09:47 large_dataset.csv
-rw-rw-r--.  1 student2 student2   140 Sep 29 09:47 numbers.txt
-rw-rw-r--.  1 student2 student2   499 Sep 29 09:47 posts.csv
-rw-rw-r--.  1 student2 student2   189 Sep 29 09:47 sample.txt
-rw-rw-r--.  1 student2 student2    67 Sep 29 09:47 small_dataset.csv
-rw-rw-r--.  1 student2 student2  2353 Sep 29 09:47 sqoop_cheatsheet.txt
[student2@osboxes ~]$ hdfs dfs -put /home/student2/data/sample.txt /user/student2/test_data/
[student2@osboxes ~]$ |
```

Рисунок 25 — Копирование `sample_data`

Сравнение размера файла в файловой системе и `hdfs` представлено на Рисунке 26.

Browse Directory

/user/student2/test_data

Go!

Show

25

entries

Search:

☐	Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name	
☐	-rw-r--r--	student2	student2	189 B	Sep 30 17:33	1	128 MB	sample.txt	

Showing 1 to 1 of 1 entries

Previous

1

Next

Hadoop, 2021.

Рисунок 26 — Сравнение размера файла

Размер файла 189 байт, но в `hadoop` ячейка занимает 128 мегабайт. Это

связано с тем, что hdfs хранит файлы в блоках с размером по умолчанию в 128 МБ.

4.2 Создание пользователей и прав

Создание пользователя analyst1 представлено на Рисунке 27.

```
[root@osboxes ~]# useradd -m -s /bin/bash analyst1
[root@osboxes ~]# passwd analyst1
Changing password for user analyst1.
New password:
BAD PASSWORD: The password contains the user name in some form
Retype new password:
passwd: all authentication tokens updated successfully.
[root@osboxes ~]# |
```

Рисунок 27 — Создание analyst1

Создание домашнего каталога для analyst1 в hdfs представлено на Рисунке 28.

```
[root@osboxes ~]# su - hadoop
Last login: Tue Sep 30 09:59:17 EDT 2025 on pts/2
[hadoop@osboxes ~]$ hdfs dfs -mkdir -p /user/analyst1
[hadoop@osboxes ~]$ |
```

Рисунок 28 — Создание домашнего каталога

Установка прав на каталог представлена на Рисунке 29.

```
[root@osboxes ~]# groupadd Sample_Group
groupadd: group 'Sample_Group' already exists
[root@osboxes ~]# usermod -a -G Sample_Group analyst1
[root@osboxes ~]# usermod -a -G Sample_Group student2
[root@osboxes ~]# su - hadoop
Last login: Tue Sep 30 11:00:23 EDT 2025 on pts/1
[hadoop@osboxes ~]$ hdfs dfs -chown analyst1:Sample_Group /user/analyst1
[hadoop@osboxes ~]$ hdfs dfs -chmod 750 /user/analyst1
```

Рисунок 29 — Установка прав на каталог

Результат проверки прав представлен на Рисунке 30.

```
[hadoop@osboxes ~]$ su - osboxes
Password:
Last login: Tue Sep 30 11:30:24 EDT 2025 on pts/1
[osboxes@osboxes ~]$ $HADOOP_HOME/bin/hdfs dfs -ls /user/analyst1
-bash: /home/hadoop/hadoop/bin/hdfs: Permission denied
[osboxes@osboxes ~]$ su - student2
Password:
Last login: Tue Sep 30 11:12:34 EDT 2025 on pts/1
[student2@osboxes ~]$ $HADOOP_HOME/bin/hdfs dfs -ls /user/analyst1
Found 1 items
-rw-r--r-- 1 osboxes Sample_Group 5 2025-09-30 11:15 /user/analyst1/testfile.txt
[student2@osboxes ~]$ |
```

Рисунок 30 — Проверка прав

Таким образом, права установлены.

4.3 Исследование блоков HDFS

Block ID: 1073741825, Block Pool ID: BP-2077243428-50.16.218.27-1756798802245 для “alice_in_wonderlands.txt”.

Проверка количества блоков для файла представлена на Рисунке 31.

```
[hadoop@osboxes ~]$ hdfs fsck /user/student2/MRtest/alice_in_wonderland.txt -files -blocks
Connecting to namenode via http://localhost:9870/fsck?ugi=hadoop&files=1&blocks=1&path=%2Fuser%2Fstudent2%2FMRtest%2Falice_in_wonderland.txt
FSCK started by hadoop (auth:SIMPLE) from /127.0.0.1 for path /user/student2/MRtest/alice_in_wonderland.txt at Tue Sep 30 11:38:01 EDT 2025

/user/student2/MRtest/alice_in_wonderland.txt 305 bytes, replicated: replication=1, 1 block(s): OK
0. BP-2077243428-50.16.218.27-1756798802245:blk_1073741825_1001 len=305 Live_rep1=1

Status: HEALTHY
Number of data-nodes: 1
Number of racks: 1
Total dirs: 0
Total symlinks: 0

Replicated Blocks:
Total size: 305 B
Total files: 1
Total blocks (validated): 1 (avg. block size 305 B)
Minimally replicated blocks: 1 (100.0 %)
Over-replicated blocks: 0 (0.0 %)
Under-replicated blocks: 0 (0.0 %)
Mis-replicated blocks: 0 (0.0 %)
Default replication factor: 1
Average block replication: 1.0
Missing blocks: 0
Corrupt blocks: 0
Missing replicas: 0 (0.0 %)
Blocks queued for replication: 0

Erasure Coded Block Groups:
Total size: 0 B
Total files: 0
Total block groups (validated): 0
Minimally erasure-coded block groups: 0
Over-erasure-coded block groups: 0
Under-erasure-coded block groups: 0
Unsatisfactory placement block groups: 0
Average block group size: 0.0
Missing block groups: 0
Corrupt block groups: 0
Missing internal blocks: 0
Blocks queued for replication: 0
FSCK ended at Tue Sep 30 11:38:01 EDT 2025 in 5 milliseconds

The filesystem under path '/user/student2/MRtest/alice_in_wonderland.txt' is HEALTHY
[hadoop@osboxes ~]$ |
```

Рисунок 31 — Количество блоков разбиения

Количество блоков зависит от размера файла и размера блока HDFS, размер файла меньше размера 1ого блока, а потому выделен 1 блок.

4.4 Работа с MapReduce

Запуск wordcount для двух файлов представлен на Рисунке 32.

```
[student2@osboxes sbin]$ hdfs dfs -cp /user/student2/test_data/sample.txt /user/student2/MRtest
cp: /user/student2/MRtest/sample.txt: File exists
[student2@osboxes sbin]$ hadoop jar $HADOOP_HOME/share/hadoop/mapreduce/hadoop-mapreduce-examples-3.3.1.jar wordcount /user/student2/MRtest /user/student2/output1
2025-09-30 11:52:08,269 INFO client.DefaultNoHARMAFailoverProxyProvider: Connecting to ResourceManager at /0.0.0.0:8032
2025-09-30 11:52:08,611 INFO mapreduce.JobResourceUploader: Disabling Erasure Coding for path: /tmp/hadoop-yarn/staging/student2/.staging/job_1759158280113_0012
2025-09-30 11:52:08,861 INFO input.FileInputFormat: Total input files to process : 2
2025-09-30 11:52:09,764 INFO mapreduce.JobSubmitter: number of splits:2
2025-09-30 11:52:10,021 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_1759158280113_0012
2025-09-30 11:52:10,021 INFO mapreduce.JobSubmitter: Executing with tokens: []
2025-09-30 11:52:10,263 INFO conf.Configuration: resource-types.xml not found
2025-09-30 11:52:10,263 INFO resource.ResourceUtils: Unable to find 'resource-types.xml'.
2025-09-30 11:52:10,354 INFO impl.YarnClientImpl: Submitted application application_1759158280113_0012
2025-09-30 11:52:10,397 INFO mapreduce.Job: The url to track the job: http://localhost:8088/proxy/application_1759158280113_0012/
2025-09-30 11:52:10,397 INFO mapreduce.Job: Running job: job_1759158280113_0012
2025-09-30 11:52:17,660 INFO mapreduce.Job: Job job_1759158280113_0012 running in uber mode : false
2025-09-30 11:52:17,662 INFO mapreduce.Job: map 0% reduce 0%
2025-09-30 11:52:25,829 INFO mapreduce.Job: map 100% reduce 0%
2025-09-30 11:52:29,874 INFO mapreduce.Job: map 100% reduce 100%
2025-09-30 11:52:30,899 INFO mapreduce.Job: Job job_1759158280113_0012 completed successfully
2025-09-30 11:52:30,992 INFO mapreduce.Job: counters: 54
```

Рисунок 32 — Запуск wordcount для двух файлов

Сравнение количества уникальных слов представлено на Рисунке 33.

```

[student2@osboxes sbin]$ hdfs dfs -cat /user/student2/output1/part-r-00000
'and' 1
'without' 1
Alice 2
Data 1
a 1
analysis 1
and 3
bank, 1
beginning 1
book 1
book,' 1
but 1
by 1
cleansing, 1
conclusions, 1
conversations 1
conversations?' 1
data 1
decision-making. 1
discovering 1
do: 1
drawing 1
get 1
goal 1
had 2
having 1
her 2
in 1
information, 1
inspecting, 1
into 1
is 2
it 1
it, 1
modeling 1
no 1
nothing 1
of 5
on 1
once 1
or 3
peeped 1
pictures 2
process 1
reading, 1
she 1
sister 2
sitting 1
supporting 1
the 5
thought 1
tired 1
to 2
transforming, 1
twice 1
use 1
useful 1
very 1
was 2
what 1
with 1

```

Рисунок 33 — Количество уникальных слов

С помощью wordcount можно проводить статистический анализ частот появления слов: строить гистограммы, анализировать частотность или проводить индексацию для дальнейшей работы с числами.

4.5 Мониторинг YARN

Запуск двух параллельных MapReduce представлен на Рисунке 34.




Рисунок 34 — Два MapReduce

Информация о выделенных ресурсах представлена на Рисунке 35.

State	FinalStatus	Running Containers	Allocated CPU VCores	Allocated Memory MB	Allocated GPUs	Reserved CPU VCores	Reserved Memory MB	Reserved GPUs	% of Queue	% of Cluster	Progress	Tracking UI	Blacklisted Nodes
ACCEPTED	UNDEFINED	0	0	0	-1	0	0	-1	0.0	0.0		ApplicationMaster	0
FINISHED	SUCCEEDED	1	1	2048	N/A	0	0	N/A	25.0	25.0		History	0

Рисунок 35 — Выделенные ресурсы

В силу недостатка ресурса ВМ для параллельного выполнения, Hadoop поставил задачи в очередь, и вторая выполнилась после завершения первой.

4.6 Исследование репликации

Изменение репликации для файла представлено на Рисунке 36.

```
drwxr-xr-x - student2 student2 0 2025-09-30 10:33 /user/student2/test_data
[hadoop@osboxes ~]$ hdfs dfs -setrep -w 2 /user/student2/MRtest/alice_in_wonderland.txt
Replication 2 set: /user/student2/MRtest/alice_in_wonderland.txt
```

Рисунок 36 — Изменение репликации

Результат изменения репликации представлен на Рисунке 37.

Browse Directory

/user/student2/MRtest

Go!









Show

25

entries

Search:

☐	Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name	
☐	-rw-r--r--	student2	student2	305 B	Sep 29 16:50	2	128 MB	alice_in_wonderland.txt	
☐	-rw-r--r--	student2	student2	189 B	Sep 30 18:50	1	128 MB	sample.txt	

Showing 1 to 2 of 2 entries

Previous

1

Next

Hadoop, 2021.

Рисунок 37 — Результат изменения репликации

Репликация используется для:

- обеспечения отказоустойчивости;
- повышения доступности данных;
- улучшения производительности при чтении (чтение с ближайшей реплики);
- защиты от потери данных при выходе из строя узлов.

Таким образом, самостоятельная работа выполнена.

ВЫВОД

В ходе выполнения практической работы были изучены основные аспекты работы с Hadoop, включая настройку и запуск служб HDFS и YARN, работу с файловой системой и управление пользователями.

Были освоены команды для взаимодействия с распределенной файловой системой HDFS, включая создание каталогов, копирование файлов, настройку прав доступа и исследование структуры хранения данных в блоках.

Практически продемонстрирована работа MapReduce фреймворка на примере задачи подсчета слов, а также проведен мониторинг ресурсов в YARN.

Особое внимание уделено вопросам безопасности и управления доступом к данным, включая настройку ACL прав и работу с группами пользователей. Были рассмотрены вопросы репликации данных и их важность для обеспечения отказоустойчивости распределенных систем.

В результате выполнения работы получены практические навыки администрирования Hadoop кластера и работы с большими данными в распределенной среде.